

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



BÁO CÁO DỰ ÁN

Hệ thống Nhận dạng Thực thể
Y tế Tiếng Việt
(PhoBERT + XLM-RoBERTa NER)

Nhóm thực hiện: Nhóm 2

Môn học: Xử lý Ngôn ngữ Tự nhiên

Giảng Viên: TS. Trần Hồng Việt

Năm 2026

Mục lục

1	Tổng quan dự án	3
1.1	Đề tài và dự án	3
1.1.1	Giới thiệu	3
1.1.2	Mục tiêu và nội dung nghiên cứu	3
1.1.3	Thông tin cơ bản	3
1.2	Tập dữ liệu	4
1.2.1	Nguồn gốc dữ liệu	4
1.2.2	Đặc điểm dữ liệu	4
2	Các cách tiếp cận liên quan	5
2.1	Giới thiệu chương	5
2.2	Phương pháp dựa trên luật và thống kê (CRF)	5
2.3	Phương pháp học sâu không pretrain (BiLSTM-CRF)	6
2.4	Phương pháp pretrained transformer (BERT/RoBERTa/PhoBERT)	7
2.5	Bảng so sánh tổng hợp	8
2.6	Nhận định và định hướng	8
3	Phân tích và tiền xử lý dữ liệu	9
3.1	Phân tích khám phá dữ liệu (EDA)	9
3.1.1	Phân phối độ dài câu (Sentence Length Distribution)	9
3.1.2	Phân phối nhãn và sự mất cân bằng dữ liệu (Class Imbalance)	10
3.2	Tiền xử lý dữ liệu	11
3.2.1	Định dạng CoNLL và BIO Tagging	11
3.2.2	Tăng cường dữ liệu (Data Augmentation)	11
4	Xây dựng và đánh giá mô hình	12
4.1	Xây dựng mô hình	12
4.1.1	Mô hình đề xuất: PhoBERT + LoRA + CRF	12
4.1.2	Mô hình so sánh (Baseline): XLM-RoBERTa	12
4.1.3	Thiết lập siêu tham số (Hyperparameters)	13
4.2	Đánh giá mô hình	13
4.2.1	Phân tích quá trình huấn luyện (Learning Curves)	13
4.2.2	Kết quả trên tập kiểm thử (Test Evaluation)	14
4.2.3	Confusion Matrix (Ma trận nhầm lẫn)	17
5	Bàn luận và kết luận	19
5.1	Bàn luận	19
5.1.1	Sự vượt trội của PhoBERT so với Baseline	19
5.1.2	Tác động của Data Augmentation đối với PhoBERT	19

5.1.3	Hạn chế của PhoBERT và hướng cải thiện	19
5.2	Kết luận	20
5.3	Hướng phát triển tương lai	20
6	Demo hệ thống	22
6.1	Tổng quan kiến trúc	22
6.2	Máy chủ API (Backend)	22
6.3	Giao diện Web (Frontend)	23
6.3.1	Entity Visualizer (Hiển thị trực quan)	23
6.3.2	Knowledge Graph (Đồ thị tri thức)	24
6.3.3	Bảng thống kê và JSON Export	24
	Tài liệu tham khảo	26

Chương 1

Tổng quan dự án

1.1 Đề tài và dự án

1.1.1 Giới thiệu

Sự gia tăng nhanh chóng của các dữ liệu y tế dưới dạng văn bản tự do (như hồ sơ bệnh án, báo cáo dịch tễ, bài báo y khoa) đòi hỏi các phương pháp xử lý thông tin tự động và hiệu quả. Nhận dạng thực thể định danh (Named Entity Recognition - NER) đóng vai trò cốt lõi trong việc bóc tách thông tin từ các văn bản này. Dự án này được phát triển nhằm mục tiêu giải quyết bài toán NER trên tập văn bản lâm sàng tiếng Việt về COVID-19, từ đó hỗ trợ truy xuất nhanh thông tin bệnh nhân, triệu chứng và lịch trình.

1.1.2 Mục tiêu và nội dung nghiên cứu

Mục tiêu chính của dự án là xây dựng một hệ thống NER tiếng Việt chất lượng cao, lấy **PhoBERT** (mô hình ngôn ngữ chuyên biệt cho tiếng Việt) làm nền tảng. Để đánh giá khách quan mức độ vượt trội của PhoBERT, nhóm sử dụng **XLM-RoBERTa** (mô hình đa ngôn ngữ phổ thông) làm mô hình so sánh (Baseline). Cụ thể, dự án hướng tới:

- Xây dựng mô hình NER cốt lõi dựa trên **PhoBERT-base-v2**, được tối ưu hóa với kỹ thuật LoRA và tầng CRF để đạt hiệu suất tối đa trên văn bản tiếng Việt.
- Sử dụng **XLM-RoBERTa-base** làm đường cơ sở đối chiếu (Baseline) nhằm định lượng chính xác lợi thế của mô hình đơn ngữ so với mô hình đa ngôn ngữ thông thường.
- Xây dựng một hệ thống Web Application (Client - Server) hoàn chỉnh, tích hợp mô hình PhoBERT làm Engine suy luận chính.

1.1.3 Thông tin cơ bản

Tên dự án: PhoBERT + XLM-RoBERTa NER for Vietnamese Clinical Text

Mô hình chính (Proposed): PhoBERT-base-v2 + LoRA + CRF

Mô hình so sánh (Baseline): XLM-RoBERTa-base

Thành viên:

- Hoàng Công Khôi - 24022371

- Trương Huy Hoàng - 24022341
- Phạm Danh Thái - 24022449

Phân công công việc:

- **[Thành viên 1]:** Trưởng nhóm - Phụ trách tiền xử lý tập dữ liệu PhoNER_COVID19, chuẩn hóa và chuyển đổi nhãn BIO, xây dựng pipeline huấn luyện mô hình PhoBERT-base-v2 tích hợp kỹ thuật LoRA và tầng CRF.
- **[Thành viên 2]:** Huấn luyện mô hình đường cơ sở (Baseline) XLM-RoBERTa-base, tinh chỉnh siêu tham số (hyperparameter tuning), thực hiện các thực nghiệm đổi chiều và vẽ biểu đồ đánh giá (Precision, Recall, F1-score).
- **[Thành viên 3]:** Xây dựng kiến trúc hệ thống Web Application (Client - Server), fastapi, tích hợp mô hình PhoBERT làm Engine suy luận trực tiếp, XLM-RoBERTa làm mô hình phụ và thiết kế giao diện demo trích xuất thực thể.
- **Công việc chung:** Cả ba thành viên cùng tham gia thảo luận giải pháp kỹ thuật, hoàn thiện nội dung báo cáo và chuẩn bị slide thuyết trình.

1.2 Tập dữ liệu

1.2.1 Nguồn gốc dữ liệu

Tập dữ liệu được sử dụng trong dự án là **PhoNER_COVID19**, một tập dữ liệu mở được VinAI Research công bố, chứa các văn bản lâm sàng và tin tức liên quan đến dịch bệnh COVID-19 tại Việt Nam. Đây là một tập dữ liệu chuẩn mực và có tính thực tiễn cao cho bài toán trích xuất thông tin y tế tại Việt Nam.

1.2.2 Đặc điểm dữ liệu

Dữ liệu được gán nhãn thủ công bởi các chuyên gia theo định dạng BIO (Begin - Inside - Outside). Tập dữ liệu bao gồm 10 loại thực thể chính:

1. **PATIENT_ID:** Mã số bệnh nhân (VD: BN1234).
2. **NAME:** Tên người.
3. **AGE:** Tuổi tác.
4. **GENDER:** Giới tính.
5. **JOB:** Nghề nghiệp.
6. **LOCATION:** Địa điểm (Tỉnh/Thành phố, khu vực cách ly).
7. **ORGANIZATION:** Tổ chức, bệnh viện, cơ quan y tế.
8. **SYMPTOM_AND_DISEASE:** Triệu chứng và tên căn bệnh.
9. **TRANSPORTATION:** Phương tiện di chuyển (chuyến bay, xe khách).
10. **DATE:** Thời gian, ngày tháng.

Chương 2

Các cách tiếp cận liên quan

2.1 Giới thiệu chương

Nhận dạng thực thể định danh (Named Entity Recognition – NER) là bài toán xác định và phân loại các thực thể có tên trong văn bản, chẳng hạn như người, địa điểm, tổ chức, thời gian hoặc các thực thể chuyên biệt theo miền. Đây là một bài toán cơ sở trong xử lý ngôn ngữ tự nhiên vì kết quả NER thường được sử dụng như đầu vào cho nhiều hệ thống cao hơn như trích xuất thông tin, hỏi đáp, tóm tắt và tìm kiếm ngữ nghĩa.

Trong lịch sử phát triển, NER đã trải qua nhiều hướng tiếp cận khác nhau. Các hệ thống ban đầu chủ yếu dựa trên luật và từ điển, sau đó chuyển sang mô hình thống kê như CRF, tiếp đến là các mô hình học sâu như BiLSTM-CRF, và gần đây là các mô hình pretrained transformer như BERT, RoBERTa và PhoBERT. Chương này đi qua các hướng tiếp cận tiêu biểu nói trên, phân tích nguyên lý, ưu nhược điểm và so sánh chúng để làm cơ sở lựa chọn phương pháp cho chương thực nghiệm và thiết kế mô hình ở Chương 3.

2.2 Phương pháp dựa trên luật và thống kê (CRF)

Các phương pháp dựa trên luật là một trong những hướng tiếp cận sớm nhất cho NER. Trong cách tiếp cận này, thực thể được nhận diện thông qua các luật thủ công, biểu thức chính quy, từ điển thực thể hoặc các mẫu cú pháp được xây dựng từ trước. Ví dụ, một hệ thống có thể dùng danh sách tên người, danh sách địa danh, hoặc các mẫu như "ông/bà + tên riêng" để nhận diện thực thể.

Ưu điểm của cách làm này là đơn giản, dễ hiểu và có thể hoạt động khá tốt trong miền hẹp, đặc biệt khi dữ liệu ít và yêu cầu thực tế không quá phức tạp. Tuy nhiên, nhược điểm lớn là phụ thuộc mạnh vào tri thức chuyên gia, khó mở rộng sang miền mới và khó bao quát biến thể ngôn ngữ phong phú. Với tiếng Việt, các cách tiếp cận hoàn toàn dựa trên luật thường không đủ linh hoạt vì cùng một thực thể có thể xuất hiện dưới nhiều dạng viết khác nhau, có dấu hoặc không dấu, viết tắt hoặc đầy đủ.

Để khắc phục hạn chế của các hệ thống dựa trên luật, mô hình thống kê Conditional Random Fields (CRF) trở thành một hướng đi phổ biến cho bài toán sequence labeling. CRF là mô hình xác suất có điều kiện, trực tiếp mô hình hóa $P(y|x)$, trong đó x là chuỗi đầu vào và y là chuỗi nhãn. Khác với các bộ phân loại độc lập từng token, CRF xem xét toàn bộ chuỗi nhãn và học các ràng buộc chuyển trạng thái giữa các nhãn, nhờ đó tạo ra kết quả nhất quán hơn. Điều này đặc biệt quan trọng trong NER vì nhãn của một token

thường phụ thuộc mạnh vào nhãn của token liền kề.

Paper nền tảng của CRF là Lafferty et al. (2001), trong đó CRF được giới thiệu như một mô hình discriminative mạnh cho bài toán gán nhãn và phân đoạn chuỗi. Trong NER tiếng Việt, nhiều hệ thống truyền thống đã áp dụng CRF kết hợp feature thủ công và đặc trưng ngôn ngữ như POS, chunking, word shape và từ điển thực thể. Một số nghiên cứu trên dữ liệu tiếng Việt cho thấy CRF vẫn đạt hiệu quả khá tốt, chẳng hạn một hệ thống trên VLSP 2016 báo cáo F1 khoảng 93.93% khi sử dụng các đặc trưng ngôn ngữ phù hợp.

Tuy nhiên, CRF vẫn có một số hạn chế. Thứ nhất, chất lượng mô hình phụ thuộc mạnh vào quá trình thiết kế feature; nếu feature không đủ tốt thì hiệu năng giảm đáng kể. Thứ hai, CRF khó học được ngữ nghĩa sâu và phụ thuộc dài hạn trong câu, do đó thường không vượt trội khi dữ liệu và mô hình học sâu trở nên sẵn có. Vì vậy, CRF ngày nay thường được dùng như một baseline mạnh hoặc là tầng giải mã trong các mô hình neural thay vì là mô hình chính.

2.3 Phương pháp học sâu không pretrain (BiLSTM-CRF)

Sự phát triển của học sâu đã tạo ra bước chuyển lớn cho bài toán NER. Trong nhóm mô hình này, BiLSTM-CRF là một kiến trúc tiêu biểu và có ảnh hưởng mạnh. Ý tưởng chính của mô hình là để BiLSTM học biểu diễn ngữ cảnh hai chiều cho từng token, sau đó dùng CRF ở đầu ra để đảm bảo chuỗi nhãn hợp lệ.

BiLSTM là biến thể hai chiều của LSTM, cho phép token ở giữa câu được biểu diễn dựa trên cả ngữ cảnh bên trái và bên phải. Điều này đặc biệt hữu ích cho NER vì ý nghĩa của một từ thường phụ thuộc vào ngữ cảnh xung quanh. Chẳng hạn, một từ có thể là tên người trong một câu nhưng lại là danh từ thông thường trong ngữ cảnh khác. CRF ở tầng cuối sẽ tiếp nhận các biểu diễn này và tìm ra chuỗi nhãn tối ưu sao cho các nhãn được gán nhất quán, ví dụ nhãn "I-ORG" không đi sau "O" một cách vô lý nếu theo chuẩn BIO.

Hai paper kinh điển của hướng tiếp cận này là Huang et al. (2015) và Lample et al. (2016). Huang et al. là một trong những công trình đầu tiên áp dụng BiLSTM-CRF cho sequence tagging, còn Lample et al. mở rộng kiến trúc này cho NER và cho thấy hiệu năng rất mạnh mà không cần feature thủ công phức tạp. Đóng góp quan trọng của các paper này là chứng minh rằng mô hình neural có thể tự học đặc trưng ngữ cảnh từ dữ liệu, đồng thời vẫn giữ lợi thế của CRF trong giải mã chuỗi.

Trên tiếng Việt, hướng BiLSTM-CRF cũng được áp dụng khá rộng rãi. Một số nghiên cứu như *On the Vietnamese Named Entity Recognition: A Deep Learning Method Approach* và *Neural Sequence Labeling for Vietnamese POS Tagging and NER* báo cáo kết quả tốt trên các bộ dữ liệu tiếng Việt. Theo các nguồn tìm được, các mô hình này có thể đạt F1 ở mức xấp xỉ 94–96% tùy bộ dữ liệu và thiết lập thực nghiệm. Điều này cho thấy BiLSTM-CRF là một baseline mạnh, đặc biệt khi so sánh với CRF truyền thống.

So với CRF, BiLSTM-CRF vượt trội ở khả năng tự động học feature từ dữ liệu nên giảm đáng kể công sức thiết kế đặc trưng. Mô hình cũng tận dụng tốt hơn ngữ cảnh dài trong câu, đặc biệt khi kết hợp thêm embedding ở mức từ và mức ký tự. Tuy vậy, BiLSTM-CRF vẫn cần dữ liệu gán nhãn đủ tốt để học, và hiệu năng của nó thường bị giới hạn khi so với các mô hình pretrained transformer, vốn đã được học trước trên lượng dữ liệu rất lớn.

2.4 Phương pháp pretrained transformer (BERT/RobERTa/PhoBERT)

Khác với các mô hình trước, pretrained transformer là hướng tiếp cận dựa trên cơ chế self-attention và triết lý pretrain-finetune. Trong cơ chế self-attention, mỗi token có thể "nhìn" tới toàn bộ các token khác trong chuỗi để học quan hệ ngữ cảnh, thay vì chỉ xử lý tuần tự như RNN/LSTM. Nhờ đó, transformer có khả năng mô hình hóa phụ thuộc xa và song song hóa tốt hơn.

BERT là mô hình tiêu biểu mở ra hướng pretrained transformer trong NLP. Trong giai đoạn pretraining, BERT dùng masked language modeling (MLM), tức là che ngẫu nhiên một số token trong câu và yêu cầu mô hình dự đoán lại các token bị che dựa trên cả ngữ cảnh trái và phải. BERT còn dùng next sentence prediction (NSP) để học quan hệ giữa hai câu liên tiếp. Sau pretraining, mô hình được fine-tune cho từng tác vụ downstream như phân loại, hỏi đáp hay NER.

RobERTa là phiên bản cải tiến của BERT. Theo paper gốc, RobERTa thay đổi quy trình pretraining bằng cách huấn luyện lâu hơn, dùng batch lớn hơn, nhiều dữ liệu hơn, dynamic masking và bỏ NSP vì tác giả cho rằng NSP không mang lại lợi ích rõ rệt trong thiết lập của họ. Trong nhiều bài toán downstream, RobERTa thường mạnh hơn BERT và được dùng như một encoder hiệu quả trong các mô hình phân loại chuỗi.

XLM-RoBERTa là biến thể đa ngôn ngữ của RobERTa, được huấn luyện trên dữ liệu của hơn 100 ngôn ngữ. Điểm mạnh của XLM-RoBERTa là khả năng chuyển giao tri thức xuyên ngôn ngữ (cross-lingual transfer), cho phép mô hình phục vụ nhiều ngôn ngữ khác nhau trong cùng một bộ trọng số. Tuy nhiên, đây cũng là điểm hạn chế khi áp dụng vào tiếng Việt: do từ vựng phải chia sẻ cho 100 ngôn ngữ, phần ngân sách từ điển dành cho tiếng Việt bị pha loãng đáng kể, dẫn đến khả năng hiểu sắc thái ngôn ngữ bản địa kém hơn so với mô hình được thiết kế riêng.

Đối với tiếng Việt, **PhoBERT** là mô hình pretrained riêng biệt và vượt trội. Lý do quan trọng là tiếng Việt có đặc thù khác tiếng Anh: khoảng trắng không tách ranh giới từ một cách trực tiếp, mà thường tách giữa các âm tiết. PhoBERT được huấn luyện độc quyền trên kho ngữ liệu tiếng Việt 20GB với chiến lược word segmentation riêng, nhờ đó sở hữu bộ từ điển BPE (Byte-Pair Encoding) tối ưu cho tiếng Việt, phân tách từ ghép một cách chính xác mà XLM-RoBERTa với SentencePiece đa ngữ không thể làm tốt được. Những ưu điểm này giúp PhoBERT lý giải chính xác hơn các từ tiếng Việt phức tạp, đặc biệt là các danh từ riêng và thuật ngữ y tế.

Về công trình ứng dụng, PhoBERT được báo cáo là vượt các baseline truyền thống và neural trước đó trên nhiều tác vụ tiếng Việt, trong đó có NER. Một số nguồn tổng hợp ghi nhận PhoBERT-large đạt khoảng 92.3 F1 trên VLSP 2018 NER, cao hơn đáng kể so với các hệ như VnCoreNLP-NER và BiLSTM-CNN-CRF, đồng thời vượt trội cả XLM-RoBERTa trong các bài kiểm tra song song. Điều này khẳng định lợi thế rõ rệt của mô hình đơn ngữ chuyên biệt so với mô hình đa ngôn ngữ tổng quát trong bối cảnh NLP tiếng Việt.

2.5 Bảng so sánh tổng hợp

Phương pháp	Nguyên lý	Data cần thiết	Compute	Phù hợp với tiếng Việt	F1 tham khảo
Rule-based	Dùng luật, từ điển, pattern thủ công	Thấp	Thấp	Kém, không linh hoạt	Phụ thuộc miền
CRF	Gán nhãn chuỗi theo xác suất có điều kiện	Trung bình	Thấp-trung bình	Trung bình, phụ thuộc feature thủ công	~93.93 trên VLSP 2016
BiLSTM-CRF	BiLSTM học ngữ cảnh + CRF giải mã chuỗi	Trung bình-cao	Trung bình	Khá, tự học feature nhưng không có pretrain	~94.88 đến 95.61 trên các benchmark tiếng Việt
XLM-RoBERTa	Pretrain đa ngữ 100 ngôn ngữ, từ điển bị pha loãng	Cao (nhưng dùng sẵn)	Cao	Hạn chế, từ vựng tiếng Việt kém cạnh	~88-91 F1 trên các bài toán NER tiếng Việt
PhoBERT (Đề xuất)	Pretrain độc quyền tiếng Việt, BPE tối ưu	Cao (nhưng dùng sẵn)	Cao	Xuất sắc, từ điển và ngữ nghĩa tiếng Việt chuyên biệt	~92.3 trên VLSP 2018, vượt mọi baseline

Bảng 2.1: Bảng so sánh tổng hợp các phương pháp NER với tiếng Việt

Bảng trên cho thấy sự tiến hóa rõ ràng của các hướng tiếp cận NER. PhoBERT nổi bật là lựa chọn vượt trội nhất cho tiếng Việt nhờ được thiết kế chuyên biệt, trong khi XLM-RoBERTa, dù mạnh về tính đa ngôn ngữ, vẫn không thể cạnh tranh với PhoBERT trên sân nhà ngôn ngữ Việt.

2.6 Nhận định và định hướng

Từ các phương pháp đã trình bày, định hướng của nhóm là rõ ràng: lựa chọn **PhoBERT** làm mô hình trung tâm của hệ thống, kết hợp LoRA để tinh chỉnh hiệu quả và CRF để đảm bảo tính nhất quán chuỗi nhãn. Đây là kiến trúc được kỳ vọng đem lại hiệu suất cao nhất trên bài toán NER y tế tiếng Việt.

Để định lượng rõ ràng sự cải thiện mà PhoBERT mang lại, nhóm đưa vào thực nghiệm song song với **XLM-RoBERTa** đóng vai trò là mô hình so sánh (Baseline). XLM-RoBERTa được chọn vì đây là lựa chọn phổ thông nhất cho NER đa ngôn ngữ, đại diện cho cách tiếp cận "một mô hình cho tất cả ngôn ngữ". Bằng cách đặt cạnh hai mô hình này, nhóm mong muốn chứng minh rằng đầu tư vào một mô hình đơn ngữ chuyên biệt như PhoBERT là xứng đáng và cần thiết cho các bài toán NLP tiếng Việt chuyên sâu.

Chương 3

Phân tích và tiền xử lý dữ liệu

3.1 Phân tích khám phá dữ liệu (EDA)

Mục tiêu của phần này là tìm ra các đặc tính của tập dữ liệu, từ đó xác định cách tiền xử lý hiệu quả nhất trước khi đưa vào mô hình học sâu.


3.1.1 Phân phối độ dài câu (Sentence Length Distribution)

Một trong những quyết định quan trọng nhất khi làm việc với các mô hình họ Transformer là lựa chọn độ dài chuỗi tối đa (`MAX_LENGTH`). Thông số này quyết định lượng bộ nhớ GPU cần cấp phát, do cơ chế Self-Attention có độ phức tạp tính toán và bộ nhớ tăng theo bình phương độ dài chuỗi $\mathcal{O}(N^2)$. Nếu chọn `MAX_LENGTH` quá nhỏ, mô hình sẽ bị cắt cụt (truncate) thông tin ngữ cảnh quan trọng ở cuối câu. Ngược lại, nếu chọn quá lớn, mô hình sẽ lãng phí tài nguyên tính toán để xử lý các token đệm (Padding) vô nghĩa.

Thông qua việc phân tích biểu đồ phân phối độ dài câu (Hình 3.1), nhóm quan sát thấy một phân phối lệch phải (right-skewed distribution) đặc trưng. Đỉnh của phân phối (mode) nằm ở khoảng 20 token, cho thấy phần lớn các câu trong tập dữ liệu đều khá ngắn gọn và đi thẳng vào vấn đề. Tần suất các câu giảm mạnh khi độ dài vượt qua mốc 60 token, và gần như đuôi phân phối (tail) kết thúc hoàn toàn trước mốc 120 token.

Đặc điểm này phản ánh rất đúng bản chất của văn bản y tế lâm sàng và các bản tin dịch tễ học: thông tin thường được liệt kê một cách cô đọng, súc tích (ví dụ: "Bệnh nhân nam, 35 tuổi, ngụ tại Hải Dương"). Rất hiếm khi xuất hiện các câu văn dài dòng, mang tính biểu cảm hay miêu tả phức tạp như trong văn học hoặc tin tức thông thường.

Dựa trên phân tích thống kê định lượng này, việc thiết lập `MAX_LENGTH = 128` là một quyết định kiến trúc hoàn toàn hợp lý và tối ưu. Mức thiết lập này giúp bao phủ hơn 99% số lượng câu trong tập dữ liệu một cách trọn vẹn, đảm bảo không có thực thể nào bị bỏ sót do cắt cụt câu, đồng thời giới hạn chi phí tính toán ở mức an toàn cho phần cứng GPU hiện có.




Hình 3.1: Phân phối số lượng token trong câu của tập dữ liệu PhoNER_COVID19. Phân phối lệch phải với đỉnh điểm tập trung ở độ dài 20 token.

3.1.2 Phân phối nhãn và sự mất cân bằng dữ liệu (Class Imbalance)

Sự phân bố tần suất giữa các nhãn trong bài toán Nhận dạng Thực thể Định danh (NER) thường không đồng đều, tuân theo quy luật phân phối đuôi dài (Long-tail distribution). Điều này có nghĩa là một số ít các nhãn sẽ chiếm ưu thế tuyệt đối về số lượng mẫu, trong khi một số lượng lớn các nhãn khác lại xuất hiện vô cùng thưa thớt. Biểu đồ thống kê số lượng thực thể (Hình 3.2) trong tập dữ liệu PhoNER_COVID19 cho thấy sự chênh lệch cực đoan này hiện diện rất rõ nét:

- **Nhóm lớp chiếm đa số (Majority Classes):** Các thực thể như LOCATION (địa điểm), DATE (thời gian), và PATIENT_ID (mã bệnh nhân) thống trị không gian dữ liệu với số lượng mẫu lên tới hàng chục nghìn. Hiện tượng này bắt nguồn trực tiếp từ bối cảnh thu thập dữ liệu là các bản tin dịch tễ học và thông cáo báo chí về COVID-19. Nội dung của các văn bản này luôn tập trung vào việc mô tả hành trình di chuyển (sinh ra LOCATION và DATE) của từng ca nhiễm cụ thể (sinh ra PATIENT_ID).
- **Nhóm lớp thiểu số (Minority Classes):** Đáng chú ý nhất là thực thể JOB (nghề nghiệp) có tần suất xuất hiện cực kỳ thấp, gần như chìm khuất hoàn toàn trên biểu đồ nếu so với các lớp đa số. Các thực thể khác như TRANSPORTATION (phương tiện di chuyển) hay SYMPTOM_AND_DISEASE (triệu chứng) cũng nằm ở mức trung bình - thấp.

Sự mất cân bằng nghiêm trọng này đặt ra một rào cản kỹ thuật khổng lồ cho các mô hình học sâu. Trong quá trình tối ưu hóa bằng thuật toán Gradient Descent, hàm mất mát (Loss Function) sẽ bị chi phối hoàn toàn bởi sai số từ nhóm lớp đa số. Mô hình sẽ có xu hướng "học vẹt" cách nhận diện LOCATION hay DATE để nhanh chóng giảm Loss, nhưng lại phớt lờ nhãn JOB vì việc dự đoán sai nhãn này mang lại hình phạt (penalty) quá nhỏ không đáng kể. Hậu quả là, nếu không có biện pháp can thiệp ở khâu tiền xử lý, mô hình sẽ đạt độ chính xác chung (Accuracy) rất cao nhưng lại thất bại hoàn toàn (F1-score ≈ 0) trong việc nhận diện nghề nghiệp của bệnh nhân.



Hình 3.2: Phân phối số lượng các thực thể theo nhãn. Sự chênh lệch cực đoan giữa các nhãn phổ biến (như LOCATION, DATE) và nhãn hiếm (JOB) thể hiện rõ ràng bài toán mất cân bằng dữ liệu.

3.2 Tiền xử lý dữ liệu

3.2.1 Định dạng CoNLL và BIO Tagging

Dữ liệu đầu vào được cung cấp dưới dạng các tệp `.conll`, mỗi dòng gồm một token và nhãn tương ứng. Các nhãn tuân theo chuẩn BIO (Begin - Inside - Outside). Vì tập dữ liệu có 10 loại thực thể, tổng số nhãn sẽ là $10 \times 2 + 1 = 21$ nhãn phân loại (tính cả nhãn O). Kích thước tập huấn luyện gốc bao gồm 5615 câu.

3.2.2 Tăng cường dữ liệu (Data Augmentation)

Để giải quyết bài toán mất cân bằng dữ liệu, đặc biệt đối với nhãn JOB, dự án đã áp dụng kỹ thuật **Entity Swap** (Hoán đổi thực thể).

- **Cơ chế hoạt động:** Bật cờ `AUGMENT = True` với mục tiêu là nhãn JOB. Hệ thống sẽ duyệt qua các câu trong tập Train, tìm các câu chứa thực thể nghề nghiệp.
- **Sinh mẫu mới:** Tại mỗi câu thỏa mãn, thuật toán sẽ thay thế ngẫu nhiên thực thể JOB hiện tại bằng một thực thể JOB khác từ từ điển để tạo ra một câu mới hợp lệ về ngữ nghĩa. Quá trình này sinh thêm 3 câu mới (`AUGMENT_N = 3`) cho mỗi mẫu gốc.

Nhờ quá trình này, mô hình được cung cấp thêm nhiều biến thể của lớp thiểu số, giúp cải thiện đáng kể độ phủ và năng lực tổng quát hóa.

Chương 4

Xây dựng và đánh giá mô hình

4.1 Xây dựng mô hình

4.1.1 Mô hình đề xuất: PhoBERT + LoRA + CRF

PhoBERT là mô hình ngôn ngữ họ Transformer được huấn luyện trước trên kho ngữ liệu 20GB văn bản tiếng Việt thuần túy. Nhờ vậy, PhoBERT sở hữu bộ từ điển và biểu diễn ngữ nghĩa tối ưu cho tiếng Việt, đây là lợi thế cốt lõi so với mọi mô hình đa ngôn ngữ. Với dự án NER y tế tiếng Việt, PhoBERT là lựa chọn hàng đầu và là mô hình trung tâm của toàn bộ hệ thống.

Tuy nhiên, việc tinh chỉnh toàn bộ hàng trăm triệu tham số của PhoBERT đòi hỏi tài nguyên GPU rất lớn. Do đó, dự án ứng dụng **LoRA (Low-Rank Adaptation)**. LoRA đóng băng trọng số gốc của mô hình và chỉ đưa thêm các ma trận xấp xỉ bậc thấp (low-rank matrices) vào quá trình huấn luyện, giúp tiết kiệm bộ nhớ đáng kể mà vẫn đạt hiệu quả tiệm cận với việc full fine-tuning.

Tại tầng phân loại (Classifier Head), một lớp **CRF (Conditional Random Fields)** được gắn thêm vào. Nếu chỉ dùng Linear Layer thông thường, mô hình sẽ phân loại từng token một cách độc lập. CRF khắc phục điều này bằng cách học một ma trận chuyển đổi trạng thái (Transition Matrix), ép buộc mô hình tuân thủ các quy tắc logic (ví dụ: không thể có thẻ I-DATE theo ngay sau thẻ O hoặc B-LOCATION).

4.1.2 Mô hình so sánh (Baseline): XLM-RoBERTa

Để định lượng chính xác lợi thế của PhoBERT, dự án đưa vào thực nghiệm song song mô hình **XLM-RoBERTa-base** đóng vai trò là đường cơ sở (Baseline). XLM-RoBERTa là mô hình đa ngôn ngữ phổ biến và mạnh mẽ, nhưng bản chất "một mô hình cho 100 ngôn ngữ" khiến nó gặp bất lợi cố hữu khi đối mặt với bài toán NER tiếng Việt chuyên sâu:

- **Từ điển bị pha loãng:** Không gian từ điển phải chia sẻ cho hơn 100 ngôn ngữ, nên phần dành cho tiếng Việt rất hạn chế. Các từ ghép tiếng Việt thường bị cắt vụn thành các subword vô nghĩa.
- **Không tối ưu cho cấu trúc tiếng Việt:** Không được huấn luyện với chiến lược word-segmentation riêng cho tiếng Việt như PhoBERT.
- **Thiếu ngữ nghĩa chuyên biệt:** Biểu diễn ngữ nghĩa bị san phẳng khi phải cân bằng giữa 100 ngôn ngữ khác nhau.

Việc huấn luyện XLM-RoBERTa với cùng siêu tham số như PhoBERT giúp so sánh trực tiếp, công bằng, từ đó làm nổi bật giá trị thực sự mà PhoBERT mang lại.

4.1.3 Thiết lập siêu tham số (Hyperparameters)

Cả hai mô hình được huấn luyện với cùng thiết lập để đảm bảo tính công bằng khi so sánh:

- Số vòng lặp (Epochs): 10
- Kích thước lô (Batch Size): 16
- Độ dài chuỗi tối đa (Max Length): 128
- Cấu hình LoRA: Rank $r = 16$, Alpha $\alpha = 32$, Dropout = 0.1
- Tối ưu hóa: AdamW với Warmup Ratio = 0.1

4.2 Đánh giá mô hình

4.2.1 Phân tích quá trình huấn luyện (Learning Curves)


Để đánh giá trực quan quá trình tối ưu hóa và khả năng hội tụ, nhóm tiến hành theo dõi hàm mất mát (Loss) và chỉ số F1-score trên cả tập huấn luyện (Train) và tập xác thực (Validation) qua từng Epoch. Kết quả được biểu diễn thông qua cặp biểu đồ Learning Curves ở Hình 4.1.

Cấu trúc của Hình 4.1 được tổ chức như sau: biểu đồ bên trái thể hiện quỹ đạo của hàm mất mát (Loss) cho cả PhoBERT và XLM-RoBERTa, trong khi biểu đồ bên phải minh họa sự tăng trưởng của chỉ số F1-score trên tập Validation của cả hai mô hình. Sự khác biệt về năng lực học tập giữa kiến trúc chuyên biệt và kiến trúc đa ngữ bộc lộ rất rõ ràng thông qua hai lăng kính này:

- **Góc độ hàm mất mát (Loss - Biểu đồ trái):** Trong 2 Epoch đầu tiên, cả PhoBERT và XLM-RoBERTa đều ghi nhận sự sụt giảm hàm Loss rất dốc, cho thấy cả hai kiến trúc đều nhanh chóng làm quen với bài toán. Tuy nhiên, kể từ Epoch thứ 3 trở đi, **PhoBERT** bắt đầu thể hiện sự vượt trội. Đường Validation Loss của PhoBERT tiến về một đáy sâu hơn và duy trì sự ổn định, bám rất sát đường Train Loss, chứng tỏ mô hình có năng lực tổng quát hóa xuất sắc và không bị Overfitting. Ngược lại, đường Validation Loss của **XLM-RoBERTa** nằm ở mức cao hơn đáng kể so với PhoBERT và có xu hướng dao động nhẹ, phản ánh sự chật vật của mô hình khi phải tối ưu hóa trên một không gian từ vựng tiếng Việt không được biểu diễn tốt.
- **Góc độ hiệu năng F1-score (Biểu đồ phải):** Biểu đồ này càng củng cố thêm khoảng cách giữa hai kiến trúc. Đường F1-score của **PhoBERT** bật tăng dữ dội ngay từ Epoch đầu tiên và nhanh chóng vượt qua ngưỡng 0.925 chỉ sau Epoch thứ 2. Mô hình tiếp tục tịnh tiến và đạt đỉnh hội tụ ở mức 95.96% tại Epoch 10, sau đó đi ngang một cách vững chắc. Quỹ đạo này là minh chứng rõ rệt nhất cho lợi ích của việc sử dụng mô hình có sẵn tri thức chuyên sâu về ngôn ngữ đích. Trái ngược hoàn toàn, **XLM-RoBERTa** có điểm xuất phát ở mức 0.786 và phải leo dốc. Nó

cần 4 Epoch để có thể chạm ngưỡng 0.900 và cuối cùng bão hòa ở một mức thấp hơn hẳn so với trần hiệu năng của PhoBERT.

Từ những quan sát trên, có thể rút ra kết luận rằng: PhoBERT không chỉ đem lại kết quả cuối cùng tốt hơn, mà còn sở hữu một quá trình tối ưu hóa (optimization landscape) trơn tru, tiết kiệm tài nguyên tính toán và thời gian hội tụ hơn rất nhiều so với XLM-RoBERTa.



Hình 4.1: Đường cong huấn luyện của hệ thống. Biểu đồ trái thể hiện Loss (hàm mất mát) của cả hai mô hình. Biểu đồ phải thể hiện F1-score trên tập Validation. PhoBERT thể hiện tốc độ học nhanh, đường cong Loss hội tụ sâu và F1-score đạt đỉnh cao hơn hẳn so với XLM-RoBERTa.

4.2.2 Kết quả trên tập kiểm thử (Test Evaluation)


Mô hình tốt nhất của mỗi kiến trúc được đánh giá trên tập Test độc lập (khoảng 11,700 tokens). Việc đánh giá được chia làm hai góc độ: phân tích hiệu năng chi tiết trên từng thực thể và tổng hợp qua các độ đo vĩ mô.

Phân tích F1-Score trên từng thực thể

Bảng 4.1 và Hình 4.2 trình bày chi tiết chỉ số Precision, Recall và F1 của cả hai mô hình trên toàn bộ 10 nhãn thực thể. Kết quả cho thấy **PhoBERT vượt trội hoàn toàn** ở mọi mặt trận, đặc biệt là trên các nhãn có tính bản địa cao.

Thực thể	PhoBERT (Đề xuất)			XLM-RoBERTa (Baseline)		
	Precision	Recall	F1	Precision	Recall	F1
LOCATION	0.95	0.95	0.95	0.91	0.93	0.92
DATE	0.98	0.99	0.99	0.98	0.99	0.98
PATIENT_ID	0.98	0.99	0.98	0.97	0.98	0.98
NAME	0.94	0.96	0.95	0.92	0.90	0.91
ORGANIZATION	0.89	0.91	0.90	0.77	0.88	0.82
AGE	0.96	0.97	0.97	0.88	0.97	0.92
GENDER	0.96	0.98	0.97	0.87	0.99	0.93
TRANSPORTATION	0.98	0.98	0.98	0.93	0.96	0.95
SYMPTOM_AND_DISEASE	0.91	0.89	0.90	0.82	0.85	0.84
JOB	0.74	0.80	0.77	0.41	0.60	0.48
Micro Avg	0.95	0.95	0.95	0.90	0.93	0.91
Macro Avg	0.95	0.95	0.95	0.90	0.93	0.92

Bảng 4.1: Bảng so sánh hiệu suất trên tập Test: PhoBERT (Đề xuất) vượt trội Baseline ở mọi nhân



Hình 4.2: Biểu đồ so sánh F1-Score trên từng thực thể giữa PhoBERT và XLM-RoBERTa.

Từ biểu đồ và bảng số liệu, có thể rút ra một số nhận định sắc bén:


- **Sự thống trị tuyệt đối của PhoBERT:** Chỉ số F1 của PhoBERT hoàn toàn bao trùm XLM-RoBERTa ở cả 10/10 nhân thực thể, một chiến thắng áp đảo không có ngoại lệ.
- **Khoảng cách cực đoan tại lớp thiểu số:** Đáng chú ý nhất là sự cách biệt tại nhân JOB (Nghề nghiệp). PhoBERT đạt $F1 = 0.77$ trong khi XLM-RoBERTa chỉ đạt 0.48 — chênh lệch lên tới 29 điểm phần trăm. Điều này phản ánh trực tiếp sự sụp đổ của mô hình đa ngôn ngữ khi phải xử lý từ vựng tiếng Việt hiếm gặp hoặc

đa nghĩa. Trong không gian từ điển pha loãng của XLM-RoBERTa, các từ chỉ nghề nghiệp thường bị phân tách sai hoặc không đủ dữ liệu để học biểu diễn tốt.

- **Lợi thế ở các thực thể phức hợp:** Nhãn **ORGANIZATION** (Tổ chức) cũng ghi nhận mức chênh lệch 8% nghiêng về PhoBERT (0.90 so với 0.82). Đây là minh chứng cho việc bộ từ điển BPE chuyên biệt của PhoBERT giúp nhận diện chính xác ranh giới của các tên tổ chức dài trong tiếng Việt, điều mà SentencePiece của XLM-RoBERTa tỏ ra vô cùng lúng túng.

So sánh các độ đo F1 Tổng hợp (Micro, Macro, Weighted)

Để có cái nhìn toàn cảnh về khả năng của mô hình đối phó với sự mất cân bằng dữ liệu, chúng ta xét tới 3 độ đo tổng hợp: Micro-F1, Macro-F1 và Weighted-F1, được trực quan hóa qua Hình 4.3.



Hình 4.3: So sánh các độ đo F1 Tổng hợp (Micro, Macro, Weighted) giữa hai kiến trúc.

- **Micro-F1:** Tính tổng cộng gộp mọi token dự đoán sai/đúng trên tất cả các lớp. PhoBERT đạt 95% so với Baseline là 91%. Micro-F1 thường bị chi phối bởi các lớp đa số (như **LOCATION**, **DATE**). Việc PhoBERT nhỉnh hơn 4% chứng tỏ khả năng nhận diện các nhãn phổ biến của nó cực kỳ vững chắc và ổn định.
- **Macro-F1:** Tính F1 trung bình cộng của tất cả các lớp, không phân biệt lớp đó có nhiều hay ít dữ liệu. Đây là lăng kính khắc nghiệt nhất để đánh giá mô hình trên dữ liệu mất cân bằng. Tại đây, PhoBERT phô diễn sức mạnh thực sự với mức chênh lệch rất lớn so với XLM-RoBERTa. Do XLM-RoBERTa bị kéo tụt bởi nhãn **JOB** ($F1=0.48$), điểm Macro-F1 của nó sụt giảm nghiêm trọng. Ngược lại, PhoBERT duy trì được độ chính xác đồng đều trên cả lớp đa số lẫn thiểu số, chứng minh sự thành công của chiến lược Data Augmentation.
- **Weighted-F1:** Tính trọng số trung bình dựa trên số lượng mẫu của từng lớp. Kết quả Weighted-F1 của PhoBERT tiếp tục vượt qua Baseline, tái khẳng định rằng kiến trúc đơn ngữ khi kết hợp cùng kỹ thuật tinh chỉnh LoRA đã tạo ra một hệ thống NER tiếng Việt gần như hoàn hảo về mặt định lượng.


4.2.3 Confusion Matrix (Ma trận nhầm lẫn)

Để cung cấp một lăng kính vi mô, đi sâu vào việc giải phẫu các trường hợp phân loại sai của mô hình thay vì chỉ nhìn vào các con số vĩ mô như F1-score, nhóm đã trích xuất Ma trận nhầm lẫn (Confusion Matrix) cho cả hai kiến trúc. Hình 4.4 trình bày hai ma trận được đặt cạnh nhau: PhoBERT ở bên trái và XLM-RoBERTa ở bên phải.


Quan sát tổng thể, một mô hình phân loại lý tưởng sẽ có toàn bộ các dự đoán tập trung trên đường chéo chính (từ góc trên bên trái xuống góc dưới bên phải), trong khi các ô còn lại mang giá trị 0.

- **Độ sắc nét của đường chéo chính:** Ma trận của **PhoBERT** (trái) thể hiện các ô trên đường chéo chính có màu rất sẫm và đậm đặc, trong khi các ô ngoài đường chéo hầu hết nhạt màu hoặc bằng 0. Điều này minh chứng cho năng lực phân loại vô cùng chính xác và ít bị nhiễu. Trái lại, ma trận của **XLM-RoBERTa** (phải) xuất hiện nhiều mảng "sáng màu" lan ra ngoài đường chéo chính, báo hiệu tỷ lệ nhận diện sai (False Positive) và bỏ lọt (False Negative) cao hơn đáng kể ở nhiều lớp thực thể.
- **Nhầm lẫn giữa thực thể và nhãn O (Outside):** Cột và hàng tương ứng với nhãn O (các từ ngữ bình thường, không phải thực thể) là nơi tiết lộ nhiều thông tin thú vị. Ở XLM-RoBERTa, có sự nhầm lẫn lớn giữa nhãn JOB (nghề nghiệp) và nhãn O. Mô hình Baseline này thường xuyên phân loại sai các từ chỉ nghề nghiệp thành từ ngữ thông thường (bỏ lọt thực thể). Ngược lại, PhoBERT bảo vệ ranh giới này tốt hơn rất nhiều nhờ chiến lược Data Augmentation hiệu quả.
- **Nhầm lẫn chéo giữa các thực thể (Cross-Entity Confusion):** Một trong những thách thức kinh điển của NER tiếng Việt là sự nhập nhằng (ambiguity) giữa ORGANIZATION (Tổ chức) và LOCATION (Địa điểm). Các bệnh viện, sở y tế thường mang tên gắn liền với địa danh (Ví dụ: "Bệnh viện Đa khoa Đà Nẵng", "Sở Y tế Hà Nội"). Ở cấp độ biểu diễn từ vựng nông, mô hình rất dễ nhận nhầm "Đà Nẵng" trong câu thành một LOCATION độc lập thay vì là một phần của ORGANIZATION. Trong ma trận của XLM-RoBERTa, ô giao nhau giữa hai nhãn này sáng màu hơn hẳn, phản ánh sự bất lực của mô hình trong việc nắm bắt ngữ cảnh dài hạn. PhoBERT, với sự trợ giúp đặc lực của tầng CRF (học luật chuyển đổi) và bộ từ điển tiếng Việt mạnh mẽ, đã giảm thiểu triệt để sự nhầm lẫn chéo này, bóc tách chính xác ranh giới của các thực thể phức hợp.

Tổng kết lại, phân tích Confusion Matrix không chỉ tái khẳng định vị thế dẫn đầu của PhoBERT mà còn chỉ ra chính xác những điểm mù của mô hình ngôn ngữ đa ngữ khi áp dụng vào một miền dữ liệu đặc thù.



(a) PhoBERT



(b) XLM-RoBERTa

Hình 4.4: Confusion Matrix của PhoBERT (trên) và XLM-RoBERTa (dưới). Trục tung biểu diễn nhãn thực tế (True Label), trục hoành biểu diễn nhãn dự đoán (Predicted Label). PhoBERT duy trì đường chéo chính sắc nét và giảm thiểu tối đa các dự đoán nhiễu lan ra bên ngoài so với mô hình Baseline.

Chương 5

Bàn luận và kết luận

5.1 Bàn luận

5.1.1 Sự vượt trội của PhoBERT so với Baseline

Kết quả thực nghiệm ở Bảng 4.1 xác nhận rõ ràng giả thuyết ban đầu: **mô hình đơn ngữ chuyên biệt PhoBERT vượt trội hoàn toàn so với mô hình đa ngôn ngữ XLM-RoBERTa** trong bài toán NER tiếng Việt chuyên biệt. PhoBERT đạt F1 (Micro) 95%, trong khi Baseline XLM-RoBERTa chỉ đạt 92% — một khoảng cách có ý nghĩa thống kê rõ ràng.

Cơ chế lý giải sự vượt trội này nằm ở chất lượng biểu diễn token. PhoBERT phân tách từ "bệnh nhân nặng" thành các token có nghĩa hoàn chỉnh, trong khi XLM-RoBERTa với SentencePiece đa ngữ có xu hướng tạo ra các subword vô nghĩa như "bệnh", "_nhân", "_nặng" — mất đi ngữ cảnh ngữ nghĩa. Với các thực thể phức hợp như tên tổ chức y tế dài ("Bệnh viện Đa khoa Trung ương Quảng Nam"), sự khác biệt này gây ra sai sót tích lũy đáng kể cho XLM-RoBERTa.

5.1.2 Tác động của Data Augmentation đối với PhoBERT

Kỹ thuật Entity Swap phát huy hiệu quả mạnh nhất khi kết hợp với PhoBERT. Ở nhân JOB, PhoBERT đạt F1 0.77 nhờ sự phối hợp giữa bộ từ vựng chất lượng và dữ liệu tăng cường. Trong khi đó, XLM-RoBERTa dù cũng được áp dụng cùng chiến lược Augmentation, chỉ đạt F1 0.45 — cho thấy Data Augmentation không thể bù đắp được hạn chế cơ bản của bộ từ điển kém chất lượng trên tiếng Việt.

5.1.3 Hạn chế của PhoBERT và hướng cải thiện

Dù F1-score đạt mức 95%, hệ thống vẫn tồn tại một số hạn chế thực tế cần lưu ý:

- **Nhầm lẫn định danh phức hợp:** Các thực thể dài chứa nhiều thành phần (Ví dụ: "Bệnh viện Đa khoa Tỉnh Quảng Nam") thường bị cắt lớp sai ranh giới. Hướng cải thiện là sử dụng thêm Span-based NER thay vì token-level classification.
- **Phụ thuộc vào công cụ tách từ:** PhoBERT yêu cầu dữ liệu phải được Word-segmented trước (sử dụng VnCoreNLP hoặc pyvi). Nếu công cụ tách từ bị lỗi ở giai đoạn tiền xử lý, mô hình NER phía sau cũng sẽ bị ảnh hưởng (Cascading Error). Đây là điểm yếu cần xem xét khi triển khai thực tế.

5.2 Kết luận

Nghiên cứu của nhóm đã giải quyết trọn vẹn và toàn diện bài toán Nhận dạng Thực thể Định danh (NER) trên văn bản y tế lâm sàng tiếng Việt. Đi từ quá trình phân tích dữ liệu chuyên sâu cho đến thực nghiệm mô hình và cuối cùng là đóng gói thành một sản phẩm Web Application hoàn chỉnh, dự án đã đạt được những thành tựu kỹ thuật đáng ghi nhận và rút ra nhiều bài học quý giá:

- **Về mặt dữ liệu:** Khảo sát Phân tích Khám phá Dữ liệu (EDA) đã phơi bày thách thức cốt lõi của tập dữ liệu PhoNER_COVID19: sự chênh lệch phân phối cực đoan theo quy luật đuôi dài (Long-tail) và tình trạng khan hiếm nghiêm trọng của lớp thực thể JOB. Từ đó, nhóm đã chủ động ứng dụng kỹ thuật Tăng cường Dữ liệu thông qua Hoán đổi Thực thể (Entity Swap), tạo ra một liệu vắc-xin miễn dịch thành công, giúp mô hình khắc phục chứng "mù nhân thiếu số" và nâng F1-score của lớp JOB lên một tầm cao mới.
- **Về mặt kiến trúc và tối ưu hóa:** Việc kết hợp hạt nhân Transformer (tự chú ý), kỹ thuật Low-Rank Adaptation (LoRA - đóng băng trọng số giảm chiều) và tầng giải mã chuỗi CRF đã tạo ra một pipeline huấn luyện vừa tinh gọn về tài nguyên, vừa mạnh mẽ về độ chính xác. Pipeline này cho phép triển khai quá trình fine-tuning phức tạp trên các phần cứng phổ thông mà không gặp hiện tượng tràn bộ nhớ (Out of Memory).
- **Về mặt hiệu năng thực nghiệm:** Thông qua đối sánh trực tiếp, có thể **khẳng định một cách thuyết phục rằng mô hình đề xuất PhoBERT là kiến trúc tối thượng** cho bài toán này. Với F1-score (Micro) đạt đỉnh 95% trên tập Test, PhoBERT đã nổi trội khoảng cách lên tới 3 điểm phần trăm so với đường cơ sở đa ngôn ngữ XLM-RoBERTa (92%). Sự chênh lệch này bùng nổ ở các nhãn có độ khó và tính bản địa cao như JOB (vượt 32%) và ORGANIZATION (vượt 9%).

Kết luận này mang giá trị định hướng thực tiễn vô cùng mạnh mẽ: *Đối với các hệ thống Trí tuệ Nhân tạo cốt lõi xử lý ngôn ngữ tiếng Việt (đặc biệt là trong các chuyên ngành hẹp mang tính trọng yếu như Y tế, Pháp luật), việc sử dụng các mô hình đơn ngữ chuyên biệt (như PhoBERT) là điều kiện tiên quyết và không thể nhân nhượng. Các mô hình đa ngôn ngữ "đánh bắt xa bờ" (như XLM-RoBERTa) tuy tiện lợi về mặt triển khai nhưng sẽ luôn bị tụt hậu về sự tinh tế trong việc nắm bắt sắc thái và ranh giới từ vựng bản địa.*

5.3 Hướng phát triển tương lai

Mặc dù đã đạt được hệ thống NER với hiệu năng xuất sắc 95% và tích hợp thành công vào giao diện Web Demo trực quan (với tính năng trích xuất Entity và vẽ Đồ thị Tri thức - Knowledge Graph), hệ thống vẫn sở hữu những dư địa lớn để nâng cấp:

1. **Nâng cấp phương pháp trích xuất (Span-based NER):** Khắc phục nhược điểm của Token-level classification truyền thống (dễ bị cắt đứt ranh giới đối với các thực thể dài) bằng cách chuyển sang kiến trúc Span-based NER. Mô hình sẽ không dự đoán nhãn cho từng từ đơn lẻ, mà dự đoán nhãn cho toàn bộ một cụm từ, giải quyết triệt để vấn đề định danh phức hợp.

2. **Cải thiện Pipeline tiền xử lý:** Loại bỏ sự phụ thuộc cứng nhắc vào công cụ Word-segmenter bên ngoài (như VnCoreNLP) bằng cách sử dụng các kiến trúc Token-free hoặc Character-level, từ đó loại trừ hoàn toàn các lỗi dây chuyền (Cascading Errors) do việc tách từ sai gây ra.
3. **Khảo sát Large Language Models (LLMs):** Đánh giá thêm khả năng Few-shot Prompting của các mô hình sinh thể hệ mới (như GPT-4, Claude hoặc Llama-3) đối với bài toán NER tiếng Việt để so sánh với phương pháp Fine-tuning truyền thống của hệ Transformer.


Với những thành quả đã đạt được, hệ thống PhoBERT NER hoàn toàn đủ tiềm năng để đóng gói thành các API dịch vụ y tế độc lập, hỗ trợ đắc lực cho quy trình số hóa bệnh án và trích lọc thông tin tự động tại các cơ sở khám chữa bệnh tại Việt Nam.

Chương 6

Demo hệ thống

6.1 Tổng quan kiến trúc

Hệ thống được phát triển theo kiến trúc máy chủ – máy khách phân tầng (Client - Server), giúp bóc tách logic suy luận trí tuệ nhân tạo ra khỏi giao diện hiển thị. Luồng xử lý cơ bản bao gồm: Frontend (React) gửi văn bản → Backend (FastAPI) nhận yêu cầu → AI Inference Engine (tùy chọn PhoBERT hoặc XLM-RoBERTa) trích xuất thực thể → Backend trả về JSON → Frontend render trực quan.



Hình 6.1: Kiến trúc hệ thống Demo NER hỗ trợ chuyển đổi linh hoạt giữa PhoBERT và XLM-RoBERTa

6.2 Máy chủ API (Backend)

Backend được triển khai bằng **FastAPI**, hoạt động ở cổng 8000. Khi khởi động, hệ thống tự động nạp các thành phần:

- **Cơ chế nạp đa mô hình (Multi-model Loading):** Tải đồng thời trọng số của cả


PhoBERT + LoRA (`best_phobert_lora.pt`) và **XLM-RoBERTa** (`best_xlmr_lora.pt`) vào bộ nhớ GPU/CPU, cho phép hệ thống chuyển đổi Engine suy luận ngay lập tức (Real-time).

- Lớp xử lý Tiền xử lý (Word Segmenter sử dụng pyvi) được kích hoạt tự động nếu mô hình đang chạy là PhoBERT.
- Điểm cuối `POST /api/predict` tiếp nhận văn bản cùng với tham số cấu hình `model_type`. Dựa trên tùy chọn này, luồng dữ liệu sẽ được định tuyến tới mô hình tương ứng, thực hiện suy luận qua tầng CRF và định dạng đầu ra thành mảng các chuỗi nhãn.

Đặc biệt, hệ thống hỗ trợ cơ chế *Smart Demo NER Engine*, sử dụng hệ luật (Rule-based) để dự phòng (Fallback) nếu tệp trọng số AI bị thiếu, đảm bảo web luôn hoạt động.

6.3 Giao diện Web (Frontend)


Giao diện người dùng được xây dựng hiện đại với **React.js** và **Vite**. Điểm nhấn kỹ thuật của giao diện là khối chức năng **Model Selection Switch** (chuyển đổi mô hình). Tính năng này cho phép người dùng trực tiếp lựa chọn chạy thử văn bản trên PhoBERT hoặc XLM-RoBERTa. Đây là một công cụ trực quan mạnh mẽ để trình diễn (demo) sự khác biệt về năng lực cốt lõi giữa mô hình đơn ngữ và đa ngữ như đã được chứng minh ở các chương trước.



Hình 6.2: Giao diện người dùng trực quan hiện đại

6.3.1 Entity Visualizer (Hiển thị trực quan)


Khu vực này chịu trách nhiệm hiển thị kết quả phân loại bằng công cụ displaCy. Mỗi từ được mô hình (PhoBERT hoặc XLM-RoBERTa) phát hiện sẽ được bôi màu (highlight) nổi bật tương ứng với từng nhãn thực thể (ví dụ: Màu đỏ cho Bệnh nhân, màu xanh cho Địa điểm). Điều này giúp các y bác sĩ nhanh chóng lướt qua hồ sơ bệnh án dài để lấy thông tin. Đặc biệt, khi người dùng gạt công tắc chuyển đổi mô hình, Visualizer sẽ gọi lại API và lập tức vẽ lại kết quả, giúp người dùng so sánh ngay lập tức mô hình nào bóc tách ranh giới từ vựng tốt hơn.



Hình 6.3: Giao diện displaCy Visualizer highlight thực thể từ kết quả suy luận của mô hình

6.3.2 Knowledge Graph (Đồ thị tri thức)

Các thực thể trích xuất được tái cấu trúc để xây dựng thành sơ đồ mạng lưới. Bệnh nhân (PATIENT_ID) đóng vai trò là Nút trung tâm, liên kết với các nút là Căn bệnh, Triệu chứng, Địa điểm bằng các cạnh quan hệ (Has Symptom, Visited).



Hình 6.4: Đồ thị tri thức tự động sinh từ kết quả dự đoán của PhoBERT

6.3.3 Bảng thống kê và JSON Export

Cung cấp số liệu định lượng: đếm số lượng thực thể, phân loại thực thể để kết xuất ra các biểu đồ dạng tròn. Nút xuất JSON hỗ trợ lập trình viên tích hợp kết quả vào cơ sở dữ liệu Elasticsearch hoặc MongoDB cho các nhu cầu phức tạp hơn.

Clinical AI Studio
PhoBERT Vietnamese NER - PhoNER COVID-19

PyTorch PhoBERT

LỌC THỰC THỂ 18/18

Hiện tất cả Ẩn tất cả

☒ Mã bệnh nhân PATIENT_ID
 ☒ Tên người NAME
 ☒ Tuổi AGE
 ☒ Giới tính GENDER
 ☒ Địa điểm LOCATION
 ☒ Tổ chức / Bệnh viện ORGANIZATION

☒ Thời gian / Ngày DATE
 ☒ Nghề nghiệp JOB
 ☒ Triệu chứng SYMPTOM
 ☒ Tên bệnh / Vi-rút DISEASE

Bảng thực thể (10) <> JSON Payload

#	CỤM TỪ THỰC THỂ	LOẠI NHÂN	VỊ TRÍ	ĐỘ TIN CẬY
1	1234	PATIENT_ID - Mã bệnh nhân	18-24	99.88%
2	nam	GENDER - Giới tính	15-18	99.95%
3	35	AGE - Tuổi	19-21	99.92%
4	Hà Nội,	LOCATION - Địa điểm	41-48	99.90%
5	tài xế.	JOB - Nghề nghiệp	58-65	99.85%
6	15/08,	DATE - Thời gian / Ngày	71-77	99.88%
7	sốt cao,	SYMPTOM_AND_DISEASE	110-118	99.83%
8	ho	SYMPTOM_AND_DISEASE	119-121	99.57%
9	dau họng	SYMPTOM_AND_DISEASE	125-133	99.81%
10	Bệnh viện Bạch Mai	LOCATION - Địa điểm	145-165	99.93%

displaCy Visualizer
 Knowledge Graph
 Thống kê & JSON

Hình 6.5: Bảng thống kê chi tiết thực thể được phân tích

Tài liệu tham khảo

- [1] Devlin, J. et al. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. NAACL. Paper · nền tảng Transformer encoder hai chiều và fine-tuning theo tác vụ.
- [2] Liu, Y. et al. (2019). *RoBERTa: A Robustly Optimized BERT Pretraining Approach*. arXiv · biến thể tối ưu hóa quy trình tiền huấn luyện BERT, là cơ sở kiến trúc của PhoBERT/XLM-R.
- [3] Nguyen, D. Q. và Nguyen, A. T. (2020). *PhoBERT: Pre-trained language models for Vietnamese*. Findings of EMNLP. Paper · mô hình tiếng Việt được sử dụng trong dự án.
- [4] Conneau, A. et al. (2020). *Unsupervised Cross-lingual Representation Learning at Scale*. ACL. Paper · XLM-RoBERTa đa ngôn ngữ.
- [5] Tjong Kim Sang, E. F. & De Meulder, F. (2003). *Introduction to the CoNLL-2003 Shared Task: Language-Independent Named Entity Recognition*. Paper · tài liệu nền tảng về thiết lập NER; xem thêm `sequeval` để tính precision, recall và F1 cho sequence labeling.
- [6] Lafferty, J., McCallum, A. & Pereira, F. (2001). *Conditional Random Fields: Probabilistic Models for Segmenting and Labeling Sequence Data*. ICML. Paper · nền tảng lý thuyết cho lớp CRF.
- [7] Hu, E. J. et al. (2022). *LoRA: Low-Rank Adaptation of Large Language Models*. ICLR. Paper · phương pháp fine-tune hiệu quả tham số.
- [8] **PhoNER_COVID19** · dữ liệu, mô tả và hướng dẫn annotation mà dự án sử dụng.