

PhoNER-COVID19

Hệ thống nhận dạng thực thể y tế tiếng Việt

Hoàng Công Khôi - Trương Huy Hoàng - Phạm Danh Thái


ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

Hà Nội, 2026

Nội dung trình bày

- 1 Tổng quan dự án
- 2 Phân tích dữ liệu
- 3 Xây dựng & Đánh giá
- 4 Kết luận
- 5 Demo hệ thống

I. Tổng quan dự án



Thách thức

- Sự gia tăng bùng nổ của văn bản y tế (bệnh án, tin tức dịch bệnh).
- Thông tin thực thể (tuổi, triệu chứng, địa điểm) nằm rải rác.
- Trích xuất thủ công hàng nghìn văn bản/ngày là **bất khả thi**.

Giải pháp: PhoNER-COVID19

Ứng dụng **Deep Learning** / **LLM** tự động phát hiện và gán nhãn thực thể y tế.

- **Tối ưu hoá khả năng hiểu ngữ nghĩa:** Sử dụng mô hình chuyên biệt cho tiếng Việt.
- **Cân bằng trade-off:** Cân bằng giữa bỏ sót thực thể (False Negative) và nhận diện sai (False Positive).
- **Triển khai end-to-end:** Xây dựng hệ thống gồm Mô hình ML + API + Web UI.

Không chỉ tối ưu Precision/Recall mà còn giải quyết bài toán thực tế:
Trích xuất nhanh, chính xác để phục vụ phân tích dịch tễ.

Nguồn: PhoNER_COVID19

Dữ liệu văn bản y tế tại Việt Nam (định dạng CoNLL), gồm 10 loại thực thể.

- **Định dạng:** CoNLL (Word-level)
- **Số lượng nhãn:** 10 (LOCATION, SYMPTOM, PATIENT_ID...)
- **Nhãn O (Ngoài thực thể):** Chiếm tỷ lệ áp đảo

Mất cân bằng cực đoan

Nhãn **O** chiếm phần lớn văn bản →
Thách thức cho phân loại.

II. Phân tích dữ liệu

Mất cân bằng nhãn - Dữ liệu thực tế

Thống kê dữ liệu


Hơn 90% token trong câu thuộc về nhãn 0 (từ vựng thông thường không mang thông tin bệnh án).

Ảo giác Accuracy

Nếu một mô hình chỉ đoán toàn bộ là nhãn 0, nó vẫn đạt Accuracy xấp xỉ 95%.


⇒ **Loại bỏ Accuracy**, tập trung sử dụng thước đo Precision / Recall / F1-score ở cấp độ thực thể (Entity-level).

Phân tích tần suất các loại thực thể



- **LOCATION** và **DATE** xuất hiện nhiều nhất.
- Các nhãn như **JOB** xuất hiện rất hiếm.

Phân phối tích lũy độ dài câu



95% số câu có độ dài dưới 128 tokens.

⇒ Cơ sở thiết lập **max_length = 128** cho mô hình Transformer, tối ưu bộ nhớ.

Đặc trưng độ dài của các thực thể

Phân bố số lượng từ (tokens)

- **Thực thể ngắn (1-2 từ):** Phổ biến nhất là AGE (VD: "32 tuổi"), GENDER (VD: "Nam", "Nữ").
- **Thực thể dài (5-10 từ):** SYMPTOM_AND_DISEASE (VD: "viêm đường hô hấp cấp"), ORGANIZATION (VD: "Bệnh viện Bệnh Nhiệt đới Trung ương").

⇒ Sự chênh lệch độ dài đòi hỏi mô hình phải có cơ chế nhận diện chuỗi (CRF) thật tốt để không cắt vụn hoặc gộp nhầm thực thể.

Phân tích tính logic & Ngữ cảnh (Co-occurrence)

Trong văn bản y tế (đặc biệt là bệnh án hoặc khai báo dịch tễ), các thực thể thường xuất hiện theo các cụm có tính logic cao:

- **Cụm Bệnh nhân:** PATIENT_ID thường đi kèm AGE và **GENDER** (VD: "Bệnh nhân 1234, nam, 32 tuổi").
- **Cụm Dịch tễ:** SYMPTOM thường xuất hiện cùng DATE và LOCATION (VD: "ho, sốt từ ngày 15/08 tại nhà").

Điều này cho thấy tầm quan trọng của cơ chế **Self-Attention** trong Transformer giúp liên kết các thực thể ở xa nhau trong câu.

Thách thức về từ vựng (Word Distribution)

Ranh giới mờ nhạt

Nhiều từ vựng có thể vừa là từ thông thường (Nhãn 0), vừa nằm trong thực thể bệnh lý (Nhãn SYMPTOM), tùy ngữ cảnh.

Từ viết tắt & thuật ngữ

Văn bản y tế chứa rất nhiều từ viết tắt, tiếng lóng hoặc lỗi chính tả (VD: "BV", "đtri", "cách li").

Giải pháp

Sử dụng **Contextual Embeddings** từ PhoBERT (đã được pre-train trên lượng lớn văn bản tiếng Việt) thay vì mô hình Word2Vec tĩnh.

1. Phân chia

Train 80% / Dev 10% / Test 10%

Đảm bảo phân phối thực thể đồng đều.

2. Tokenization

Tách từ (Word-level) tiếng Việt (VnCoreNLP/pyvi).
Phù hợp với pre-trained PhoBERT.

3. Cấu trúc nhãn

Chuyển đổi BIO.

Data Augmentation (Hoán đổi thực thể) để giảm mất cân bằng.

III. Xây dựng & Đánh giá

Các mô hình được thử nghiệm

Rule-based

Sử dụng từ điển, Regex.
(Làm Baseline / Smart Demo)

XLM-RoBERTa

Mô hình Transformer đa ngôn ngữ.
Tokenize dạng Subword (BPE).

PhoBERT

Transformer chuyên biệt tiếng Việt.
Tokenize dạng Word-level.
Lựa chọn chính

Tất cả mô hình Neural đều kết hợp kỹ thuật LoRA và tầng CRF.

Sức mạnh của PhoBERT trong Tokenization

Vấn đề với mô hình đa ngôn ngữ (XLM-R)

Bị nhiễu bởi bộ từ vựng chung của 100 ngôn ngữ. Làm vỡ các từ ghép tiếng Việt (Syllable-level BPE), ví dụ "bệnh viện" có thể bị cắt thành các subword không có ý nghĩa hình thái.

Giải pháp của PhoBERT

Sử dụng tokenizer dành riêng cho tiếng Việt (Word-level), hiểu trọn vẹn ngữ nghĩa của các từ ghép y khoa.

⇒ **PhoBERT** duy trì ranh giới từ (word boundaries) hoàn hảo, đóng vai trò sống còn trong bài toán NER.


- **LoRA (Low-Rank Adaptation):**

- Đóng băng phần lớn trọng số của LLM.
- Chỉ huấn luyện 1% tham số mới → File checkpoint nhỏ gọn, train nhanh.

- **CRF (Conditional Random Fields):**


- Học quy luật chuyển đổi nhãn (Transition Matrix).
- Loại bỏ lỗi phi logic (VD: Không bao giờ có nhãn I-AGE đứng trước B-AGE).

Quá trình huấn luyện



Sử dụng Learning rate decay, early stopping.
PhoBERT hội tụ ổn định và đạt hiệu năng cao trên tập Validation.


Đánh giá Entity-level F1




PhoBERT phân hoá rõ rệt, F1 tổng thể cao hơn hẳn XLM-R trên hầu hết các lớp.

Confusion Matrix: PhoBERT vs XLM-R

PhoBERT



XLM-RoBERTa



PhoBERT nhận diện chính xác hầu hết các nhãn y tế, ít lỗi nhầm lẫn hơn so với XLM-R.

IV. Bàn luận & Kết luận

Trade-off: Precision vs Recall

Trong bài toán NER y tế, luôn tồn tại một sự đánh đổi:

- **Thiên về Precision (Độ chính xác):**

Ít dự đoán rác, nhưng dễ **bỏ sót** bệnh lý của bệnh nhân.

- **Thiên về Recall (Độ bao phủ):**

Bắt đủ các triệu chứng, nhưng dễ **cảnh báo giả** (nhầm từ thông thường thành bệnh).

Mô hình **PhoBERT + CRF** đã tối ưu xuất sắc điểm cân bằng này, với cả Precision và Recall đều duy trì ở mức cao và đồng đều.

Hạn chế của XLM-RoBERTa trong thực tế

1. Hiện tượng "Cross-lingual Interference"

Do phải học không gian biểu diễn của quá nhiều ngôn ngữ, khả năng bám sát ngữ cảnh hẹp của tiếng Việt bị giảm sút so với mô hình đơn ngữ như PhoBERT.

2. Tokenizer không phù hợp

Việc mã hóa bằng SentencePiece sinh ra các token bị chia nhỏ sai về mặt hình thái học tiếng Việt, dẫn đến việc ranh giới thực thể (Entity Boundaries) liên tục bị dự đoán lệch 1-2 ký tự.

3. Kết quả

Tốc độ hội tụ chậm hơn, dễ bị Overfitting sớm trên tập huấn luyện kích thước nhỏ.

Tại sao chọn PhoBERT?

Hiệu năng tốt nhất

Chiến thắng tuyệt đối ở 3 chỉ số quan trọng: Precision, Recall và F1-score.

Ưu điểm nổi bật

- Giải quyết triệt để lỗi ranh giới thực thể (Boundary detection).
- Tối ưu tài nguyên phần cứng cực tốt khi kết hợp với kỹ thuật PEFT (LoRA).
- Dễ dàng mở rộng cho các bài toán NLP Y tế chuyên sâu hơn trong tương lai (vd: Trích xuất quan hệ - Relation Extraction).

Dữ liệu

Khắc phục mất cân bằng bằng phương pháp tăng cường dữ liệu và thước đo phù hợp (F1).

Mô hình


PhoBERT + LoRA + CRF khẳng định sức mạnh của LLM cục bộ.

Hệ thống

Xây dựng thành công ứng dụng đầu cuối (FastAPI + React) với độ trễ thấp.

PhoNER-COVID19 kết hợp thành công:
phân tích dữ liệu → xây dựng mô hình → đánh giá thực nghiệm → triển khai hệ thống demo.

V. Demo hệ thống



3 lớp: Mô hình ML (PhoBERT) $\longleftrightarrow$ FastAPI (Backend) $\longleftrightarrow$ React/Vite (Frontend)

Quản lý trạng thái Real-time

Giao diện Frontend được thiết kế để luôn cập nhật trạng thái kết nối với Backend, hiển thị trực quan thông báo tới người dùng.

Chuyển đổi Mô hình (Engine Switch)

Tích hợp Menu cho phép người dùng tự do chuyển đổi giữa:

- **PhoBERT Engine** (Deep Learning)
- **XLM-RoBERTa Engine** (Deep Learning)
- **Smart Demo Mode** (Rule-based Fallback khi chưa load mô hình)

Trải nghiệm người dùng (UX)


Thiết kế vùng nhập liệu rộng rãi, hỗ trợ paste dữ liệu từ hồ sơ bệnh án hoặc tin tức dịch tễ một cách nhanh chóng.

Dữ liệu mẫu (Sample)

Tích hợp sẵn các câu văn mẫu điển hình giúp người dùng nhanh chóng trải nghiệm năng lực của mô hình mà không cần gõ phím.

Xử lý bất đồng bộ (Asynchronous) thông qua FastAPI giúp trả kết quả **nhANH CHóNG** và không chặn giao diện.

Giao diện - Kết quả dự đoán (Span Highlight)



Văn bản được tô màu (Highlight) trực quan các thực thể: Bệnh lý, Địa điểm, Thời gian...

Giao diện - Bảng trích xuất JSON & Phân tích

Dữ liệu có cấu trúc

Toàn bộ thực thể trích xuất được đóng gói thành một tệp JSON (Key-Value) rõ ràng, sẵn sàng truyền tải sang các hệ thống khác (ví dụ lưu vào Database).

Đồ thị liên kết thực thể (Dossier View)

Giao diện cung cấp chế độ xem trực quan liệt kê từng loại thực thể đã thu thập, hỗ trợ bác sĩ hoặc nhà nghiên cứu dễ dàng lập hồ sơ (Dossier) của người bệnh.

Giảm thiểu 90% thời gian đọc hiểu văn bản y tế cho con người.

Thank you!